

SQL HowTo **Алгоритмы на графах**

Это не граф





... а барон

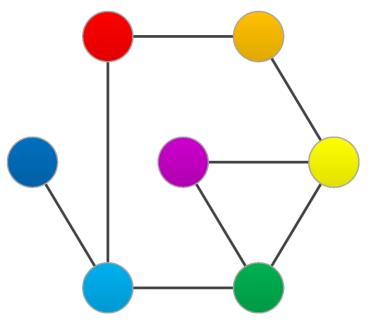
Это – граф



... да не тот



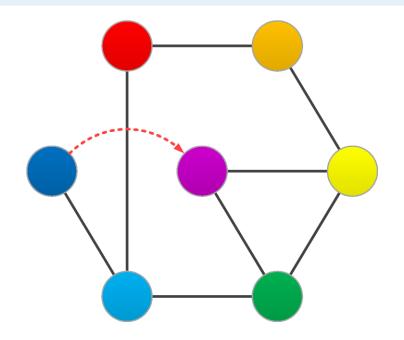
Это – граф

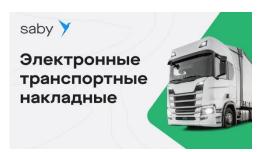


набор вершин, соединенных ребрами

Поиск кратчайшего пути на планарном графе.

https://ru.wikipedia.org/wiki/Алгоритм_Ли

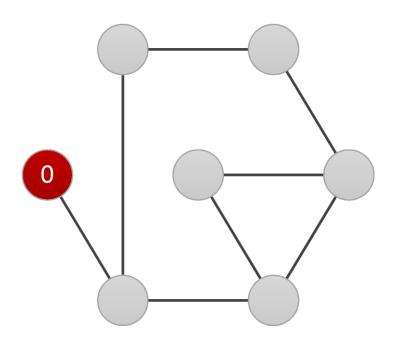




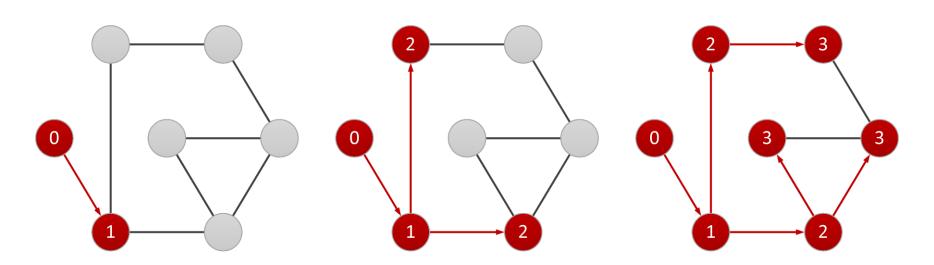
Saby TMS



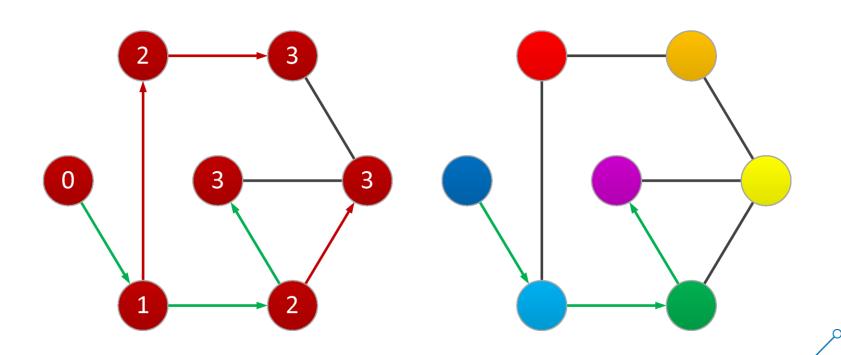
Шаг 1: инициализация волны



Шаг 2: распространение волны



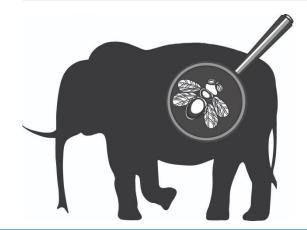
Шаг 3: восстановление пути



«Правила игры очень просты: надо построить цепочку слов от начального (*МУХА*) до конечного (*СЛОН*), на каждом шаге меняя только одну букву. При этом могут использоваться только русские 4-буквенные нарицательные существительные в начальной форме: например, слова *БАЗА, НОЧЬ, САНИ* допускаются, а слова ЛИТЬ, ХОТЯ, РУКУ, НОЧИ, САНЯ, ОСЛО, АБВГ, ФЦНМ — нет.

Эта игра под названием «Дублеты» приобрела известность благодаря Льюису Кэрроллу — не только автору книг про Алису, но ещё и замечательному математику. В марте 1879 года он начал раз в неделю публиковать в журнале «Ярмарка тщеславия» по три задания в форме броских фраз: «Turn *POOR* into *RICH*» — «Преврати бедного в богатого», «Evolve *MAN* from *APE*» — «Выведи человека из обезьяны», «Маке *TEA HOT*» — «Сделай чай горячим». В том же году он выпустил брошюру «Дублеты», подробно описал в ней правила и предложил читателям попрактиковаться на нескольких десятках примеров.»

Александр Пиперски, <u>"Из мухи — слона"</u>, «Квантик» <u>№2, 2019</u> и <u>№3, 2019</u>



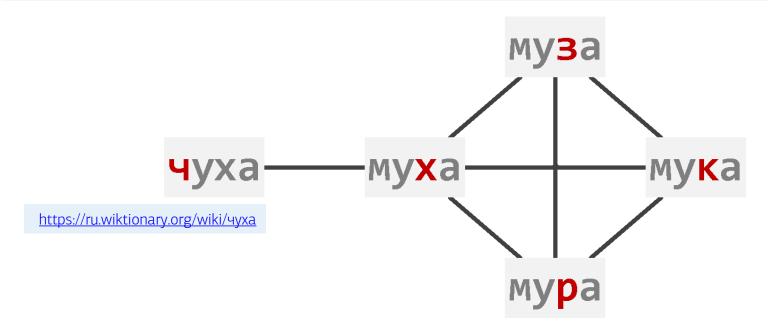
Шаг 1: загружаем словарь (словарь Ефремовой, 51К существительных)

https://harrix.dev/blog/2018/russian-nouns/

```
CREATE TABLE dict AS
 SELECT
   btrim(word) word -- зачищаем пробелы с обеих сторон
  FROM
    regexp_split_to_table($$
абажур
абажурчик
абаз
абазин
-- ...
   $$, E'[\r\n]') word -- делим текст на строки
 WHERE
   word !~ '^\s*$': -- загружаем только непустые строки
```

Шаг 1: загружаем словарь (словарь Ефремовой, 51К существительных)

https://harrix.dev/blog/2018/russian-nouns/



Шаг 2: формируем ребра графа

https://postgrespro.ru/docs/postgresql/16/pgtrgm

https://postgrespro.ru/docs/postgresql/16/btree-gin

https://postgrespro.ru/docs/postgresql/16/textsearch-indexes

```
CREATE EXTENSION pg_trgm;
CREATE EXTENSION btree_gin;
CREATE INDEX ON dict USING gin(
 length(word) -- для этого - btree_gin
, word gin_trgm_ops -- для этого - pg_trgm
);
```

Шаг 2.1: формируем наборы LIKE-шаблонов

```
CREATE TABLE pair AS
 WITH src AS MATERIALIZED (
    SELECT
    FROM
      dict
    , LATERAL (
        SELECT
          array_agg( -- 'myxa' -> {'_yxa', 'm_xa', 'my_a', 'myx_'}
            overlay(word PLACING '_' FROM i)
          ) patterns -- массив всех возможных LIKE-шаблонов замены одной буквы
        FROM
          generate_series(1, length(word)) i
      ) T
```

Шаг 2.2: ищем «парные» слова по набору шаблонов

```
SELECT
 src.word src
, dst.word dst
FROM
 src
, LATERAL (
    SELECT
     word
    FROM
      dict
   WHERE
      length(dict.word) = length(src.word) AND -- ищем только в той же длине
      dict.word LIKE ANY(src.patterns) AND -- одновременно по набору шаблонов
      dict.word <> src.word
                                              -- исключая исходное слово
 ) dst;
```

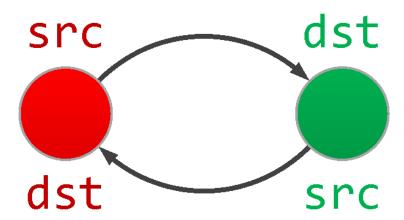
Шаг 2.2: ищем «парные» слова по набору шаблонов

#	node, ms	io.rd, ms i	o.wr, ms tree, ms	rows	RRbF Q loops	
		136.758	8.542 56'461.607	35/916	102/602	• итоговые результаты ($\frac{2.2MB}{2}$ = rows= $\frac{35'916}{2}$ x width= $\frac{64}{2}$)
.0	111.292		56'461.607	35′916 ▼		ested Loop
1					%	CTE src
.2	43.648		672.306	51'301		-> Nested Loop
.3	13.046	.198	.016	51/301	% T W	-> Seq Scan on dict dict_1
4	410.408		615.612	51/301	51′301	-> Aggregate
.5	205.204			461′709 ▼	51′301 %	-> Function Scan on generate_series i
.6	67.725		740.031	51/301	90	-> CTE Scan on src
.7	461.709	136.560	8.526 55'610.284	51′301 ▼	102'602 66.7% 51'301 %	-> Bitmap Heap Scan on dict
	55/148.575			564′311 ▼	51/301	-> Bitmap Index Scan on dict_length_word_idx (cost=0.000.13 rows=13 width=0) (actual time=1.0751.075 rows=11 loops=51'301 Index Cond: ((length(word) = length(src.word)) AND (word ~~ ANY (src.patterns))) Buffers: shared hit=10'558'976
						lanning
	.246					lanning Time
	107.390		56′568.997			xecution Time



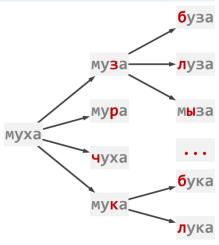
Шаг 2.3: индексируем ребра графа

CREATE UNIQUE INDEX ON pair(src, dst);



Шаг 3.1: запускаем «волну»

```
WITH RECURSIVE param(src, dst) AS (
  VALUES('муха', 'слон')
, s2d AS (
  SELECT
   0 i
            -- счетчик шага
  , ARRAY[src] path -- уже пройденный волной путь
  , ARRAY[src] diff -- "прирост" на новом шаге
 FROM
    param
UNION ALL
```



Шаг 3.1: запускаем «волну»

```
. . .
UNTON ALL
 SELECT
   i + 1
 , T.path || dst$ -- добавляем узлы в пройденный путь
 , dst$
 FROM
   s2d T
  , LATERAL (
    -- тут поиск узлов следующего шага волны -->
   ) X
  , param
 WHERE
   dst <> ALL(path) AND -- останавливаемся, дойдя до цели
   i < 100 -- не более чем за 100 шагов
```

```
-- следующий шаг волны
SELECT
 array_agg(dst) dst$ -- сворачиваем в массив все достигнутые узлы
FROM
 pair
WHERE
 src = ANY(T.path) AND -- для всех оснований добавляем следствия,
 dst <> ALL(T.path) -- которые еще не принадлежат пути
```

Шаг 3.1: запускаем «волну»

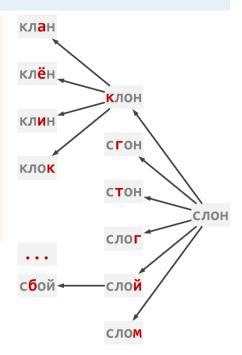
```
i | path | diff
0 | {муха}
0 | {муха}
1 | {муха,муза,мука,мура,чуха}
1 | {муха,муза,мука,мура,чуха}
2 | {муха,муза,мука,мура,чуха,буза,луза,мыза,бука,лука,рука,сука,фука,щука,аура,бура,дура,кура,мера,сура,тура,фура,чоха,чума}
| {буза,луза,мыза,бука,лука,рука,сука,фука,щука,аура,бура,дура,кура,мера,сура,тура,фура,чоха,чума}
...
11 | ...
```

Всего 11 шагов – и мы на месте!

Шаг 3.2: запускаем «волну» обратно

```
, d2s AS (
SELECT

(SELECT max(i) FROM s2d) i -- уже знаем, сколько будет шагов
, ARRAY[dst] path
-- теперь начинаем «с конца»
, ARRAY[dst] diff
FROM
param
UNION ALL
...
```



Шаг 3.2: запускаем «волну» обратно

```
. . .
UNION ALL
 SELECT
   i - 1 -- счетчик теперь идет «вниз»
  , T.path || dst$
 , dst$
 FROM
   d2s T
  , LATERAL (
    -- тут поиск узлов следующего шага волны -->
   ) X
  , param
 WHERE
   src <> ALL(path) AND -- останавливаемся, дойдя до начала
   i > 0
```

```
-- следующий шаг волны

SELECT

array_agg(dst) dst$

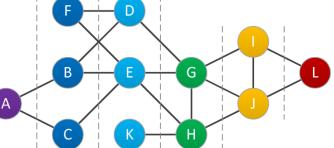
FROM

pair

WHERE

src = ANY(T.path) AND

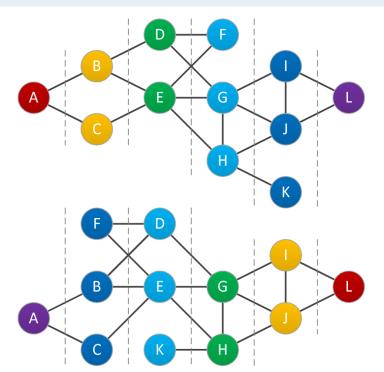
dst <> ALL(T.path)
```

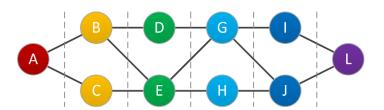


Шаг 3.2: запускаем «волну» обратно

... обратный отсчет

Шаг 3.3: совмещаем «туда» и «обратно»





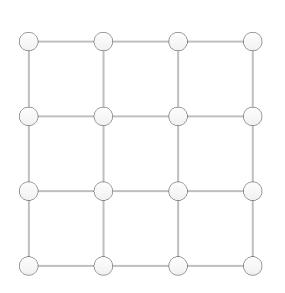
Шаг 3.3: совмещаем «туда» и «обратно»

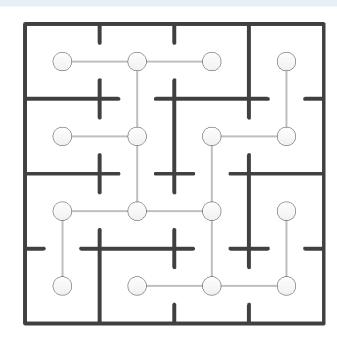
```
SELECT
, unnest(ARRAY( -- потенциально, тут может оказаться несколько слов
   SELECT unnest(s2d.diff) -- развернули первый массив
 INTERSECT ALL
                -- нашли пересечение наборов
   SELECT unnest(d2s.diff) -- развернули второй массив
 )) word
FROM
 s2d
JOIN
 d2s
   USING(i);
```

```
word
     муха
     мура
     фура
     фара
     фарт
     фаут
     паут
     плут
     плот
     клот
10
     клон
11
     СЛОН
```

Построение минимального остовного дерева связного взвешенного графа.

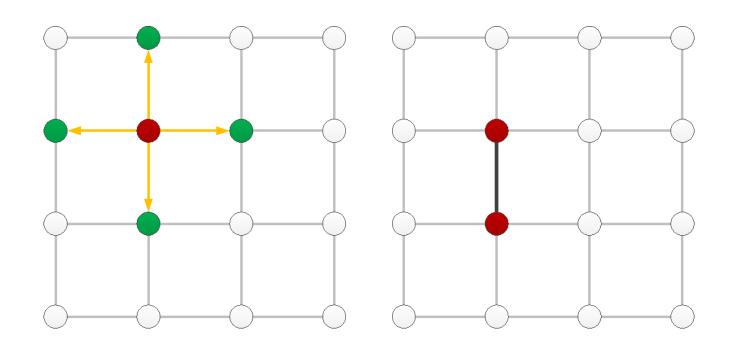
https://ru.wikipedia.org/wiki/Алгоритм Прима



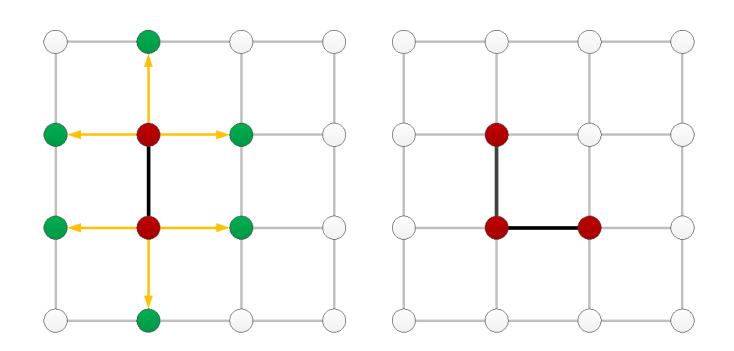




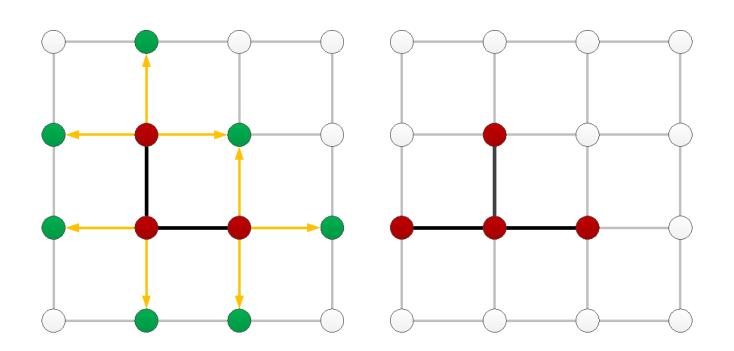
Шаг 1: стартуем с произвольной точки



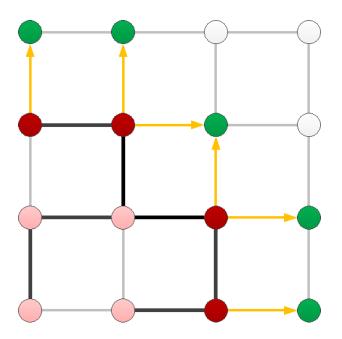
Шаг N: добавляем вершину из достижимых за минимальное расстояние



Шаг N: добавляем вершину из достижимых за минимальное расстояние

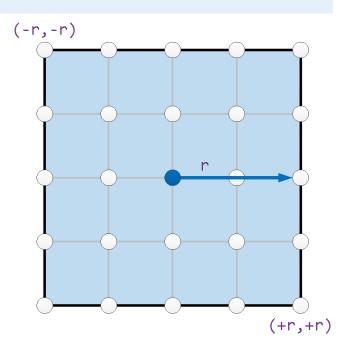


Шаг N: добавляем вершину из достижимых за минимальное расстояние



Шаг 1: обозначим границы лабиринта

```
-- задаем "радиус" лабиринта
WITH RECURSIVE sz(r) AS (
 VALUES(2)
-- границы лабиринта
, box AS (
 SELECT
   box( -- прямоугольник по противоположным углам
     point(-r, -r)
    , point(+r, +r)
  FROM
    SZ
```



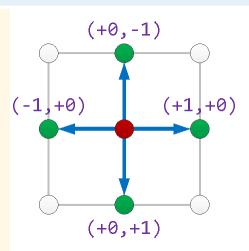
Шаг 2: рекурсивный «цикл»

```
-- цикл выбора ребер
, T AS (
 SELECT
   ARRAY[p]::point[] points -- уже достигнутые точки
  , ARRAY[p]::point[] wavefront -- фронт "волны"
  , NULL::lseg edge -- выбранное ребро
  FROM
   SZ
  , point( -- случайная стартовая точка
     (random() * 2 * r)::integer - r
    , (random() * 2 * r)::integer - r
   ) p
UNION ALL
```

```
UNION ALL
  -- ... Hic sunt dracones
 WHERE
    array_length(T.points, 1) = 1 OR -- стартовый шаг
   T.edge IS NOT NULL -- продолжаем, пока можно выбрать ребро
```



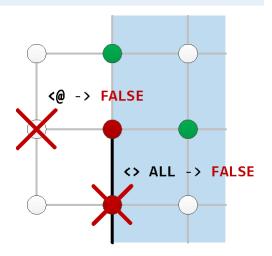
Шаг 2.1: ребра до «соседей»



Шаг 2.2: проверка принадлежности лабиринту, но не дереву

```
, LATERAL (
    SELECT e[1] d -- получаем "целевые" точки из отрезков
) Y

WHERE
    d <@ (TABLE box) AND -- точка должна находиться в границах box
    d <> ALL(T.points) -- и не должна быть достигнута ранее
```



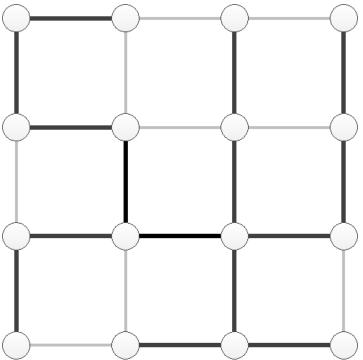
Шаг 2.3: формируем «фронт»

```
SELECT
   array_agg(e) edges -- все полученные ребра
, array_agg(DISTINCT s::text)::point[] wavefront -- новый фронт - все возможные "источники" предыдущего шага
```

Шаг 2.4: выбираем ребро

```
SELECT
 T.points || X.edge[1] -- "хвост" выбранного ребра добавляем к достигнутым точкам
, X.wavefront || X.edge[1] -- ... и к фронту
, X.edge
FROM
 Т
, LATERAL (
    SELECT
     z.wavefront
    , Z.edges[(random() * (array_length(Z.edges, 1) - 1))::integer + 1] edge -- выбираем случайное ребро из набора
      -- (array_sample(Z.edges, 1))[1] B PostgreSQL 16+
    FROM
     ) Z
 ) X
```

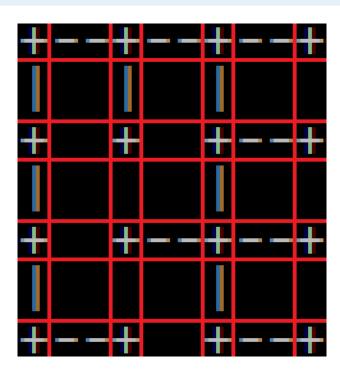
```
-- цикл выбора ребер
, T AS (
 SELECT
   ARRAY[p]::point[] points -- уже достигнутые точки
  , ARRAY[p]::point[] wavefront -- фронт "волны"
  , NULL::1seg edge
                               -- выбранное ребро
 FROM
  . point( -- случайная стартовая точка
     (random() * 2 * r)::integer - r
   , (random() * 2 * r)::integer - r
   ) p
UNION ALL
 SELECT
   T.points | X.edge[1] -- "хвост" выбранного ребра добавляем к достигнутым точкам
 , X.wavefront || X.edge[1] -- ... и к фронту
  , X.edge
 FROM
 , LATERAL (
     SELECT
      , Z.edges[(random() * (array_length(Z.edges, 1) - 1))::integer + 1] edge -- выбираем случайное ребро из набора
     FROM
         SELECT
           array agg(e) edges -- все полученные ребра
          , array_agg(DISTINCT s::text)::point[] wavefront -- новый фронт - все возможные "источники" предыдущего шага
           unnest(T.wavefront) s -- для каждой точки фронта
          , LATERAL ( -- формируем все 4 возможных ребра
               (lseq(s, point(s[0] - 1, s[1])))
             (1seg(s, point(s[0] + 1, s[1])))
             , (lseg(s, point(s[0], s[1] - 1)))
             , (lseg(s, point(s[0], s[1] + 1)))
           ) X(e)
          , LATERAL ( -- получаем "целевые" точки
             SELECT e[1] d
           ) Y
          WHERE
           d <@ (TABLE box) AND -- целевая точка должна находиться в границах лабиринта
           d ⇔ ALL(T.points) -- и не должна быть достигнута ранее
   ) X
 WHERE
   array_length(T.points, 1) = 1 OR -- стартовый шаг
   T.edge IS NOT NULL
                                   -- продолжаем, пока можно выбрать ребро
```



Шаг 3: делаем «красиво»: удвоенная координатная сетка

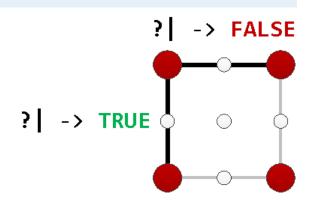
N	еН	N	еН	N	еН	N
eV		eV		eV		eV
N	еН	N	еН	N	еН	N
eV		eV		eV		eV
N	еН	N	еН	N	еН	N
eV		eV		eV		eV
N	еН	N	еН	N	еН	N

Шаг 3: делаем «красиво»: адаптация шрифта



Шаг 3.1: готовим ребра

```
-- приводим ребра в удобный вид
, edges AS (
 SELECT
   point(edge) * point(2, 0) cx2 -- удваиваем координаты центра ребра
  , CASE
     WHEN ?| edge THEN '|' -- вертикальный отрезок
     ELSE '---'
   END v -- определяем его положение (вертикально/горизонтально)
 FROM
   т
 WHERE
   edge IS NOT NULL
```



Шаг 3.2: заполняем сетку

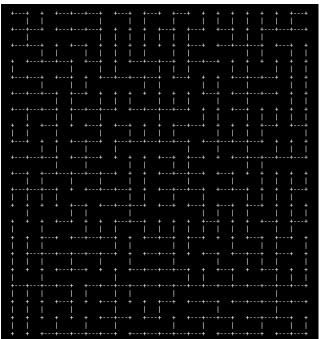
```
-- заполняем координатную сетку
, map AS (
 SELECT
   m.*
  , CASE
     WHEN x \% 2 = 0 AND y \% 2 = 0 THEN '+'
     WHEN x \% 2 = 0 THEN coalesce(v, '')
     ELSE coalesce(v, ' ')
   END V
 FROM
   (...) т -- удвоенная координатная сетка ->
 LEFT JOIN
   edges
     ON point(x, y) \sim= cx2 -- point = point
```

Шаг 3.3: собираем итоговый вывод

```
-- рисуем картинку
SELECT
  string_agg(v, '' ORDER BY x) maze
FROM
  map
GROUP BY
  y
ORDER BY
  y;
```

$$r = 2$$

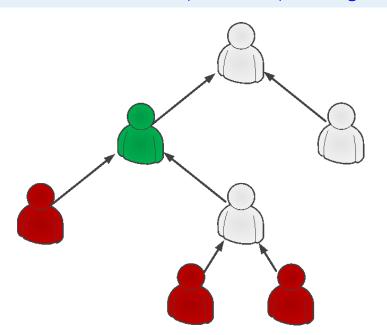
```
-- приводим ребра в удобный вид
, edges AS (
 SELECT
   point(edge) * point(2, 0) cx2 -- удваиваем координаты центра ребра
     WHEN ?| edge THEN '|' -- вертикальный отрезок
   END v -- определяем его положение (вертикально/горизонтально)
 WHERE
   edge IS NOT NULL
-- заполняем координатную сетку
, map AS (
 SELECT
   m.*
 , CASE
     WHEN x \% 2 = 0 AND y \% 2 = 0 THEN '+'
     WHEN x \% 2 = 0 THEN coalesce(v, '')
     ELSE coalesce(v. ' ')
   FND V
   ( -- удвоенная координатная сетка
     SELECT
       х
      , у
     FROM
     , generate_series(-r * 2, r * 2) x
      , generate_series(-r * 2, r * 2) y
 LEFT JOIN
     ON point(x, y) ~= cx2 -- point = point
-- рисуем картинку
 string_agg(v, '' ORDER BY x) maze
FROM
 map
GROUP BY
ORDER BY
 у;
```



$$r = 10$$

Он же «наименьший» или «нижайший» (LCA, lowest (least) common ancestor).

https://ru.wikipedia.org/wiki/Наименьший общий предок

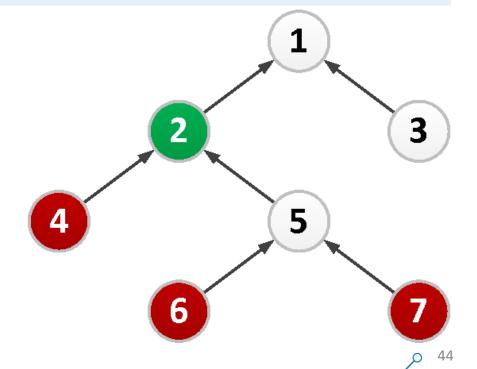




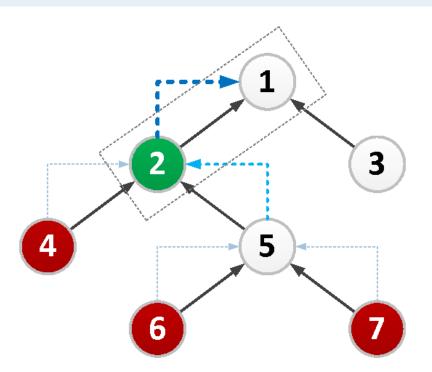
Saby Staff | Saby HRM

```
Шаг 1: исходное дерево
```

```
WITH RECURSIVE tree(id, pid) AS (
 VALUES
    (1, NULL)
  (2, 1)
  , (3, 1)
  , (4, 2)
  , (5, 2)
  , (6, 5)
  (7, 5)
```



Наивный алгоритм: общий префикс всех путей



$$1 - 2 - 4$$

$$1 - 2 - 5 - 6$$

$$1 - 2 - 5 - 7$$

Наивный алгоритм: шаг 1 – генерируем все пути

```
, path AS (
  SELECT.
   ARRAY[id] p
  FROM
    tree
  WHERE
    id = ANY('{4,6,7}'::integer[]) -- отбираем исходные узлы
UNION ALL
  SELECT
    array_prepend(tree.pid, p) -- новый элемент добавляем в начало
  FROM
    path
  , tree
  WHERE
    tree.id = path.p[1] AND -- "шагаем" от последнего добавленного узла
    tree.pid IS NOT NULL -- выше корня не идем
```

```
{6}
{7}
{2,4}
{5,6}
{5,7}
\{1,2,4\}
{2,5,6}
{2,5,7}
\{1,2,5,6\}
```

Наивный алгоритм: шаг 2 – оставляем нужные пути

```
, path2root AS (
    SELECT DISTINCT ON(p[ln]) -- уникализируем по последнему (исходному) элементу
    p
, ln
FROM
    path
, array_length(path.p, 1) ln -- однократно вычисляем длину массива-пути
ORDER BY
    p[ln]
, ln DESC -- оставляем самые длинные пути
)
```

```
    p
    In

    {1,2,4}
    3

    {1,2,5,6}
    4

    {1,2,5,7}
    4
```

Наивный алгоритм: шаг 3 – определяем длину общего префикса

```
, pos AS (
 SELECT
 FROM
   path2root
 . generate_series(
   , (SELECT min(ln) FROM path2root) -- длина кратчайшего из путей
   ) i
                                    -- перебираем все индексы до нее
 GROUP BY
                -- группируем по длине префикса
 HAVING
   count(
     DISTINCT p[:i] -- префикс из і первых элементов ...
   ) = 1 -- ... единственный
```

```
i
1
2
```

Наивный алгоритм: шаг 4 – получаем последний элемент префикса = LCA

```
SELECT
  p[(SELECT max(i) FROM pos)] node
FROM
  path2root
LIMIT 1;
```

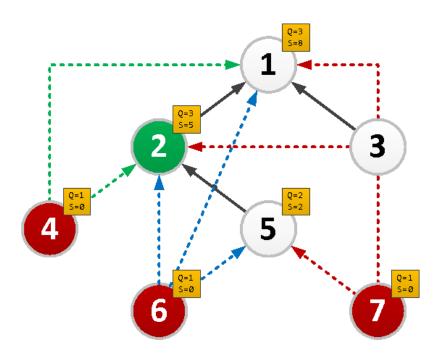
node 2

Наивный алгоритм: ... непросто

```
WITH RECURSIVE tree(id, pid) AS (
 VALUES
   (1, NULL)
  , (2, 1)
  (3, 1)
  (4, 2)
  , (5, 2)
  (6, 5)
  , (7, 5)
, path AS (
 SELECT
   ARRAY[id] p
 FROM
    tree
 WHERE
   id = ANY('{4,6,7}'::integer[]) -- отбираем исходные узлы
UNION ALL
 SELECT
    array_prepend(tree.pid, p) -- новый элемент добавляем в начало
 FROM
    path
  . tree
 WHERE
   tree.id = path.p[1] AND -- "шагаем" от последнего добавленного узла
    tree.pid IS NOT NULL -- выше корня не идем
```

```
, path2root AS (
 SELECT DISTINCT ON(p[]n]) -- уникализируем по последнему (исходному) элементу
  , ln
 FROM
  , array_length(path.p, 1) ln -- однократно вычисляем длину массива-пути
 ORDER BY
   p[]n]
  . In DESC -- оставляем самые длинные пути
, pos AS (
 SELECT
 FROM
   path2root
  , generate_series(
    , (SELECT min(ln) FROM path2root)
   ) i -- перебираем все индексы до длины кратчайшего пути
 GROUP BY
                    -- группируем по длине префикса
 HAVING
   count (
     DISTINCT p[:i] -- префикс из і первых элементов ...
                 -- ... единственный
SELECT
 p[(SELECT max(i) FROM pos)] node
FROM
 path2root
LIMIT 1;
```

Счетчик посещений: максимум путей при минимуме длины



Счетчик посещений: шаг 1 – считаем посещения каждого узла

```
, path AS (
 SELECT
   id src -- откуда вышли
  , id dst -- докуда уже дошли
        -- за сколько шагов
 FROM
   tree
 WHERE
   id = ANY('{4,6,7}'::integer[])
UNION ALL
 SELECT
   path.src
  , tree.pid
  , s + 1 -- увеличиваем путь на 1 пройденное ребро
 FROM
   path
  . tree
 WHERE
   tree.id = path.dst AND -- шагаем от последнего посещенного узла
   tree.pid IS NOT NULL
```

```
dst
src
  6
  6
  6
  6
```

Счетчик посещений: шаг 2 – считаем посещения каждого узла

```
SELECT
 dst
                 -- ищем среди всех достигнутых узлов
FROM
 path
GROUP BY
                 -- группируем по тому же dst
ORDER BY
 count(src) DESC -- максимум количества узлов-источников
, sum(s) -- минимум суммы пройденных путей
LIMIT 1;
```

dst 2

Счетчик посещений: подключаем PostgreSQL 14+

```
, path AS (
  SELECT
   id src
  . id dst
  FROM
    tree
  WHERE
   id = ANY('{4,6,7}'::integer[])
UNION ALL
  SELECT
    path.src
  . tree pid
  FROM
    path
  , tree
  WHERE
    tree id = path.dst
) SEARCH DEPTH FIRST BY dst SET path
```

Счетчик посещений: подключаем PostgreSQL 14+

```
SELECT
  dst
                  -- ищем среди всех достигнутых узлов
FROM
  path
GROUP BY
                  -- группируем по тому же dst
ORDER BY
  count(src) DESC -- максимум количества узлов-источников
, sum(array_length(path, 1)) -- минимум суммы пройденных путей
LIMIT 1;
```

dst

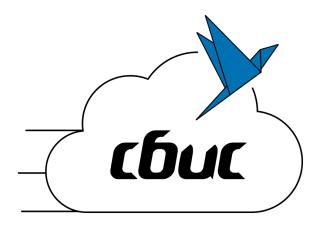
Итоги

Алгоритм Ли — кратчайший путь в графе Из мухи — слона

Алгоритм Прима — минимальное остовное дерево Строим лабиринт (+ геометрические типы данных)

Ближайший предок в дереве поиск в глубину (SEARCH DEPTH)





Спасибо за внимание!

Боровиков Кирилл

kilor@tensor.ru / https://explain.tensor.ru

sbis.ru / tensor.ru